

Laboratorio 5 — Agentes en el Arcade Learning Environment: Space Invaders

CC3092 · Deep Learning y Sistemas Inteligentes

Código, notebook y videos del laboratorio: github.com/ecarcamo/CC3092-DEEP-LEARNING/tree/main/lab5

1. El Arcade Learning Environment

El Arcade Learning Environment (ALE) convierte los juegos originales del Atari 2600 en entornos de aprendizaje por refuerzo con una interfaz uniforme. El problema que resuelve es metodológico: antes de ALE cada investigador evaluaba su algoritmo en un dominio construido por él mismo, lo que introduce *sesgo del diseñador* —quien diseña el método diseña también la prueba— e impide comparar resultados entre artículos. ALE ofrece más de cien tareas diseñadas por terceros, programadores de videojuegos de los años ochenta sin ninguna intención de servir como *benchmark* de IA, todas con la misma interfaz: píxeles de entrada y una acción de joystick como salida. Eso permite plantear la pregunta de la inteligencia general de dominio, y es el banco de pruebas donde se validaron DQN, A3C, Rainbow y Agent57.

ALE no reimplementa los juegos: se construye sobre Stella, un emulador libre del Atari 2600, y ejecuta los mismos ROMs comerciales con la misma lógica y los mismos errores que el cartucho de 1980. Stella emula el hardware (CPU 6507, chip gráfico TIA, 128 bytes de RAM) y produce la imagen de 210×160; ALE añade encima la capa que lo vuelve un entorno de RL: expone una API de agente, elimina la interfaz humana —el entorno corre *headless* y mucho más rápido que en tiempo real, lo que hace viable entrenar con millones de cuadros—, define dónde termina un episodio (el cartucho original nunca termina, vuelve a la pantalla de inicio) y define la recompensa, que el ROM no emite: lee la puntuación de una dirección conocida de la RAM del juego y entrega la diferencia entre dos pasos consecutivos. Desde `ale-py 0.9` los ROMs vienen incluidos en el paquete y ya no hace falta AutoROM.

1.1 Variantes del mismo juego

Un mismo ROM da lugar a muchos entornos. Estos son los identificadores registrados para Space Invaders en la instalación de este laboratorio, con sus valores por defecto:

Identificador	frameskip	repeat_action_probability	full_action_space
SpaceInvaders-v0	(2, 5)	0.25	False
SpaceInvaders-v4	(2, 5)	0.0	False
SpaceInvadersNoFrameskip-v0	1	0.25	False
SpaceInvadersNoFrameskip-v4	1	0.0	False
ALE/SpaceInvaders-v5	4	0.25	False

Los `v0` y `v4` son identificadores heredados de OpenAI Gym que se conservan por compatibilidad; el namespace `ALE/...` -`v5` es el actual y sus valores por defecto implementan las recomendaciones de Machado et al. (2018). El `frameskip` indica cuántos cuadros del emulador se ejecutan por cada acción; la tupla `(2, 5)` de los ids antiguos muestreaba ese número al azar, que era como Gym introducía estocasticidad. El `repeat_action_probability` (*sticky actions*) hace que con probabilidad 0.25 el entorno ignore la acción nueva y repita la anterior: como el 2600 es determinista, sin ruido un agente puede «resolver» un juego memorizando una secuencia fija en lazo abierto sin mirar la pantalla, y Machado et al. mostraron que una búsqueda trivial superaba así a agentes de RL sofisticados. El `full_action_space` expone las 18 acciones legales del joystick en todos los juegos en vez del conjunto mínimo de cada uno, que es lo que necesita un agente multijuego con una sola cabeza de salida. Los antiguos sufijos `-ram` fueron retirados en `ale-py 0.12` y se sustituyen por el argumento `obs_type`.

1.2 Frame skipping

El 2600 corre a 60 cuadros por segundo, y decidir 60 veces por segundo es un problema por tres razones. Por velocidad: el costo dominante no es emular el juego sino la inferencia de la red en cada decisión, así que con `frameskip=4` el agente hace una cuarta parte de las pasadas hacia adelante y la simulación se acelera de forma casi lineal en k . Por asignación de crédito: un episodio de 1 800 cuadros pasa a 450 pasos, con menos descuento acumulado y menos pasos por los que propagar la recompensa hacia atrás. Y por escala temporal: un humano reacciona en torno a 200 ms, y $k = 4$ da 15 decisiones por segundo, además de producir movimientos más sostenidos. También tiene costos: con k grande el agente pierde control fino y puede no reaccionar a eventos rápidos, y cambiar k cambia el horizonte efectivo que representa un mismo γ , de modo que dos configuraciones no son directamente comparables.

Ligado a esto: el TIA dibuja varios sprites en cuadros alternos, y Space Invaders es un caso de manual. Medición propia: ejecutando 1 200 cuadros con la acción NOOP, con `frameskip=1` los proyectiles aparecen en 346 observaciones, mientras que con el `frameskip=4` por defecto de la `v5` no aparecen en ninguna: se dibujan justo en los cuadros que el salto

descarta. Esa es la razón de que el preprocesamiento estándar tome el máximo píxel a píxel de los dos últimos cuadros en lugar del último, y tiene una consecuencia práctica directa, descrita en la sección 3.

1.3 Space Invaders: mecánica y recompensa

Arcade de Taito (1978) adaptado por Atari al 2600 en 1980. El jugador controla un cañón láser que solo puede moverse horizontalmente y disparar hacia arriba, frente a una formación de invasores que se desplaza lateralmente y desciende cada vez que toca un borde mientras deja caer proyectiles. El objetivo es destruir la formación antes de que llegue abajo. La dificultad la definen tres elementos: la formación acelera conforme quedan menos invasores, hay búnkeres destructibles que se erosionan también con los disparos propios, y una nave nodriza cruza por arriba otorgando una bonificación mayor. En ALE el jugador tiene 3 vidas y el episodio termina al agotarlas.

El juego solo incrementa un marcador en pantalla; ALE lo lee de la RAM y define la recompensa como la diferencia de puntuación entre dos pasos consecutivos. De ahí tres consecuencias de diseño. La recompensa es no negativa: perder una vida no penaliza, su costo es solo la recompensa futura que se deja de obtener, y por eso al entrenar suele añadirse `terminal_on_life_loss`. Es escalonada y dispersa: casi todos los pasos dan cero, y los invasores de las filas superiores valen más. Y su escala es arbitraria y distinta en cada juego, lo que motiva recortar la recompensa a su signo en el protocolo de DQN. El retorno del episodio coincide exactamente con la puntuación final de la partida.

2. Espacios de observación y acción

La observación por defecto de ALE/SpaceInvaders-v5 es `Box(0, 255, (210,160,3), uint8)`: la imagen RGB de la pantalla, 100 800 valores. `CartPole-v1`, del laboratorio anterior, entrega `Box((4,), float32)` con posición, velocidad, ángulo y velocidad angular: 4 valores. La diferencia de 25 200× en dimensionalidad no es lo más importante. Lo verdaderamente distinto es que en CartPole el estado ya viene interpretado —alguien decidió cuáles son las variables relevantes y las entrega medidas—, mientras que en Atari el agente recibe lo mismo que un humano y debe descubrir por sí mismo que ciertos grupos de píxeles son un cañón y otros el marcador irrelevante.

Las implicaciones son cinco. Hay que aprender la representación: con cuatro números basta una política lineal, y de hecho en el laboratorio anterior una regla escrita a mano resolvía CartPole; con 100 800 píxeles hace falta un extractor de características, y por eso aquí aparecen las redes convolucionales. Un solo cuadro no es un estado: una imagen fija no dice hacia dónde se mueve la formación ni si un proyectil sube o baja, de modo que la observación es parcialmente observable y viola la propiedad de Markov, que el vector de CartPole sí cumple. Sobra información: color, marcador, vidas y fondo no aportan a la decisión. Cambia la escala de memoria: un cuadro RGB ocupa unos 100 KB y un búfer de repetición de un millón de transiciones sin preprocesar pediría unos 100 GB. Y la eficiencia de muestras se desploma: miles de pasos en CPU frente a decenas de millones de cuadros y GPU.

Con `obs_type="ram"` la observación pasa a ser `Box(0,255,(128,),uint8)`: los 128 bytes completos de memoria de la consola, donde viven las posiciones de los sprites, la puntuación y las vidas. Es literalmente el estado del juego. Conviene con recursos limitados, porque 128 valores admiten un MLP que entrena en CPU; cuando lo que se estudia no es la percepción sino la exploración o el control, porque la visión solo añade ruido y costo; y porque el estado es completo y sin parpadeo, casi markoviano sin apilar cuadros, lo que además lo hace útil para depurar. No conviene porque la codificación es específica de cada juego y opaca —campos de bits y valores BCD—, así que no transfiere a otro juego, que es justo lo que ALE existe para medir; porque es información privilegiada que un humano no ve, lo que invalida la comparación con puntajes humanos; y porque no es comparable con la literatura, que reporta resultados sobre píxeles.

El espacio de acción de Space Invaders es `Discrete(6)`, el conjunto mínimo del juego: `NOOP` (ni se mueve ni dispara, sirve para esperar o mantener posición), `FIRE` (dispara sin moverse), `RIGHT` y `LEFT` (se desplaza sin disparar) y `RIGHTFIRE` y `LEFTFIRE` (se desplaza y dispara en el mismo paso). `UP` y `DOWN` existen en el joystick pero no hacen nada aquí. Las acciones combinadas importan mucho, porque reflejan que en el 2600 el botón y la palanca son independientes: un agente restringido a moverse o disparar jugaría claramente peor. Con `full_action_space=True` el espacio pasa a `Discrete(18)`.

`AtariPreprocessing` empaqueta el preprocesamiento estándar de DQN (Nature, 2015): `noop_max=30` ejecuta entre 1 y 30 `NOOP` al reiniciar para aleatorizar el estado inicial; `frame_skip=4` repite la acción cuatro cuadros y devuelve el máximo píxel a píxel de los dos últimos, corrigiendo el parpadeo medido en 1.2 —exige `frameskip=1` en el entorno base, o el salto efectivo sería de 16—; `screen_size=84` redimensiona a 84×84; `grayscale_obs=True` elimina el color, que en Atari casi nunca es informativo; y `scale_obs=False` mantiene `uint8` en vez de `float32`, lo que supone cuatro veces menos memoria en el búfer de repetición. Conviene precisar que el recorte de recompensa, aunque forma parte del pipeline clásico de DQN, no está dentro de `AtariPreprocessing` en Gymnasium: vive en `ClipReward`. Separarlos tiene sentido, porque el recorte altera el objetivo que se optimiza mientras que las demás transformaciones solo cambian la representación.

`FrameStackObservation` (llamado `FrameStack` antes de Gymnasium 1.0) apila las últimas N observaciones en un nuevo eje. Su razón de ser es la ya señalada: un cuadro no basta para determinar el estado, y con cuatro consecutivos la velocidad y la dirección quedan implícitas en la diferencia entre ellos. Por eso ambos wrappers se usan siempre juntos: uno hace cada cuadro barato y limpio, el otro le devuelve la dimensión temporal. El pipeline completo lleva la observación de

100 800 a 7 056 y finalmente a 28 224 valores: es 3.6 veces más pequeña que la imagen original y aun así contiene más información útil, porque incorpora cuatro instantes en lugar de uno.




Figura 1. Observación cruda frente a los cuatro cuadros apilados que recibiría la red. Los trazos verticales visibles en los cuadros procesados son los proyectiles que el *max-pooling* recupera y que la observación por defecto pierde.

3. Módulo de funciones desarrollado

El módulo `src/ale_utils.py` concentra la infraestructura y se demuestra en el notebook. `crear_entorno` crea el entorno y, si recibe `video_folder`, lo envuelve en `gymnasium.wrappers.RecordVideo` con el `episode_trigger` indicado; reenvía `**kwargs` a `gym.make`, así que sirve igual para Space Invaders que para CartPole-v1 o para pedir `obs_type="ram"`. `agente_aleatorio` devuelve `env.action_space.sample()` como línea base. `ejecutar_episodio` corre hasta que `terminated` o `truncated` sean verdaderos, o hasta `max_steps`, y devuelve los pasos y el retorno acumulado. `generar_video_agente` combina las anteriores: crea el entorno con grabación, juega `n_episodios`, cierra el entorno y devuelve las rutas de los videos con las métricas de cada episodio.

Tres decisiones de implementación merecen mención. El `env.close()` va dentro de un `finally`, porque sin esa llamada el `.mp4` se queda a medias y no llega a escribirse a disco. La ruta de cada video se deriva del índice de episodio en vez de listar la carpeta, de modo que las métricas no se desalinean cuando `episode_trigger` graba solo algunos episodios ni se recogen videos de ejecuciones anteriores. Y `ejecutar_episodio` siembra también `env.action_space.reset(seed=...)` siembra el generador del entorno pero no el del espacio de acción, así que sin esa segunda siembra el agente aleatorio jugaba una partida distinta en cada ejecución con la misma semilla.

Se añadió además `agente_regla_simple`, una política fija sin aprendizaje que localiza el cañón y los invasores por su color en la imagen, descarta los invasores cuya columna está tapada por un búnker —disparar ahí destruye la propia cobertura en lugar de sumar puntos— y se desplaza hacia el invasor alcanzable más cercano disparando a la vez con `RIGHTFIRE` o `LEFTFIRE`. La tolerancia de apuntado es de 4 px, media anchura de un invasor (se midieron 8 px exactos). No esquiva los proyectiles enemigos, y no por simplificar: como se midió en 1.2, con el `frameskip=4` por defecto son invisibles en la observación.

4. Resultados

Se generaron dos videos de episodios completos en ALE/SpaceInvaders -v5, y se comparó a los dos agentes sobre diez episodios con las mismas semillas:

Agente	Video: pasos	Video: recompensa	Retorno medio (10 ep.)	Desv. típica	Pasos medios
agente_aleatorio	298	35	123.5	73.3	461.0
agente_regla_simple	552	260	246.0	34.8	522.1

El agente de regla simple duplica el retorno del aleatorio con menos de la mitad de desviación típica y gana en las diez semillas, sin haber aprendido nada: solo mirando colores. Pero conviene decir lo incómodo: una política degenerada que se queda quieta disparando obtiene 285.0 de retorno medio, por encima de las dos. Buena parte del mérito no está en apuntar sino en no dejar de disparar nunca, porque la formación acaba pasando por encima del cañón de todos modos; y moverse tiene un costo real, porque con *sticky actions* el movimiento es impreciso y, sobre todo, es a ciegas. Ese último punto conecta las dos mitades del laboratorio: la medición de la sección 1.2 no es un detalle teórico, es exactamente lo que le impide a este agente esquivar. El preprocesamiento estándar de Atari no es burocracia: resuelve un problema que aquí se puede tocar con la mano.

Para un agente que sí aprenda, la infraestructura no cambia: basta apilar `AtariPreprocessing` y `FrameStackObservation` sobre `crear_entorno`, añadir el recorte de recompensa y sustituir la función de agente por una red que estime $Q(s,a)$.

Referencias

Bellemare, M. G., Naddaf, Y., Veness, J. y Bowling, M. (2013). *The Arcade Learning Environment: An Evaluation Platform for General Agents*. JAIR, 47, 253–279. • Machado, M. C., Bellemare, M. G., Talvitie, E., Veness, J., Hausknecht, M. y Bowling, M. (2018). *Revisiting the Arcade Learning Environment*. JAIR, 61, 523–562. • Mnih, V. et al. (2015). *Human-level control through deep reinforcement learning*. Nature, 518, 529–533. • Documentación de Gymnasium (gymnasium.farama.org), de ale-py (ale.farama.org) y del emulador Stella (stella-emu.github.io).